

Basic stats about teosinte data (v2 — corregido)

Samantha Melissa Pacheco Gómez

2026-08-18

Introducción

Vamos a analizar la metadata de teosintes del artículo “Genomic diversity and population structure of teosinte (*Zea* spp.) and its conservation implications” (Rivera-Rodríguez et al. 2023, PLOS ONE, <https://doi.org/10.1371/journal.pone.0291944>), con datos genómicos descargados de Dryad (<https://doi.org/10.5061/dryad.2547d7wpx>).

Esta es una **versión corregida y reordenada** del análisis exploratorio inicial (`basic_analysis_teosinte.pdf`). La revisión detectó que la variable `POB_CODE` de la metadata individual **no corresponde** a las “276 teosinte populations” que reporta el paper (Materials and methods) — esa unidad corresponde a **Accession**. Todo lo que sigue usa **Accession** como unidad de población, y se apoya en el passport data del paper (S1 Data) para confirmarlo y para tener información más completa (p. ej. razas de todos los taxa, no solo de ssp. *mexicana*).

Fuentes de datos

Ajusta las rutas según donde tengas cada archivo:

```
ruta_metadata <- "/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/data_teosinte.csv" # metadata
ruta_passport <- "/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/passport_data.xlsx" # S1 Data
ruta_fam <- "/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/T3604_33929_all.fam" # PLI
ruta_bim <- "/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/T3604_33929_all.bim" # PLI
ruta_bed <- "/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/T3604_33929_all.bed" # PLI
ruta_worldclim <- "/home/sam/Documents/sur_ecoevo_lab/data/worldclim/mesoamerica_30s.tif" # 19 variables
```

Archivo	Nivel de los datos	Filas esperadas	Qué aporta
<code>data_teosinte.csv</code>	individuo	3604	genotipado, <code>POB_CODE</code> , coordenadas, taxón
<code>passport_data.xlsx</code> (S1 Data)	población	276	Accession , Race completo, Label , localidad de colecta
<code>T3604_33929_all.{bed,bim,fam}</code>	individuo / SNP	3604 ind. x 33,929 SNPs	genotipos
<code>worldclim_..._mesoamerica_30s.tif</code>	población (vía coordenadas)	—	19 variables ambientales

```
library(dplyr)
library(readxl)
library(SNPrelate)
```

```
Data      <- read.csv2(ruta_metadata, header = TRUE, sep = ",", as.is = FALSE)
passport <- read_excel(ruta_passport, sheet = 1)
```

¿Qué es una “población” aquí? (CORRECCIÓN)

El paper dice que trabajó con 276 poblaciones de teosinte, respaldadas por el S1 Data (justo passport_data.xlsx). Comprobemos qué variable de la metadata corresponde a eso:

```
length(unique(Data$POB_CODE))      # 74 -> NO son las 276 poblaciones del paper
```

```
## [1] 74
```

```
length(unique(Data$Accession))      # 276 -> esta sí es la unidad de "población" del paper
```

```
## [1] 276
```

```
nrow(passport)                      # 276 filas: 1 fila = 1 población
```

```
## [1] 276
```

POB_CODE agrupa varias Accession distintas (probablemente corresponde a un sitio/región más amplio visitado durante la expedición, dentro del cual hay varias poblaciones genéticas puntuales):

```
rel <- Data %>%
  group_by(POB_CODE) %>%
  summarise(n_accessions = n_distinct(Accession),
            n_localities = n_distinct(Locality), .groups = "drop") %>%
  arrange(desc(n_accessions))
```

```
rel
```

```
## # A tibble: 74 x 3
##   POB_CODE n_accessions n_localities
##   <fct>      <int>      <int>
## 1 BVPU          9          9
## 2 AMEC          8          8
## 3 BGUA          8          8
## 4 BTEJ          8          8
## 5 BZAC          8          8
## 6 CHAP          8          8
## 7 CHPU          8          8
## 8 BEJU          7          7
## 9 BHUE          7          7
## 10 BTZI         7          7
## # i 64 more rows
```

```
summary(rel$n_accessions)           # media ~3.7, máximo 9 accessions por POB_CODE
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.00    2.00    3.00    3.73    5.00    9.00
```

Y cada `Accession` sí es una unidad geográfica puntual (1 sola lat/lon, 1 solo `POB_CODE`):

```
chequeo <- Data %>%
  group_by(Accession) %>%
  summarise(n_lat = n_distinct(Latitude), n_lon = n_distinct(Longitude),
            n_pobcode = n_distinct(POB_CODE), .groups = "drop")

all(chequeo$n_lat == 1 & chequeo$n_lon == 1 & chequeo$n_pobcode == 1)
```

```
## [1] TRUE
```

Unir la metadata individual con el passport data (por `Accession`)

Un `Accession` no empata directamente entre archivos por un problema menor de formato (sinónimos concatenados en el passport: "CIM9479_ Ames21880_ PI441934" vs "CIM9479" en el csv). Lo corregimos y unimos:

```
passport <- passport %>%
  rename_with(~ gsub("\\s+", " ", trimws(.x))) # quita espacios sobrantes de TODOS los nombres
sum(is.na(Data$Label)) # individuos sin match -> debe ser 0
```

```
## [1] 0
```

Resumen general de los datos

```
str(Data)
```

```
## 'data.frame': 3604 obs. of 16 variables:
## $ DNASample_code: Factor w/ 3603 levels "1_11","1_12",...: 208 209 210 207 211 212 213 214 215 216 ...
## $ Library_plate : Factor w/ 44 levels "P_Teo_01_b","P_Teo_03_b",...: 39 26 26 26 26 26 26 26 26 26 ...
## $ POB_CODE      : Factor w/ 74 levels "AMEC","BAPX",...: 68 68 68 68 68 68 68 68 68 68 ...
## $ POB_NUMBER    : int 66 66 66 66 66 66 66 66 66 66 ...
## $ Accession     : Factor w/ 276 levels "CIM10003","CIM11083",...: 110 110 110 110 110 110 110 110 110 110 ...
## $ Race          : Factor w/ 6 levels "", "Balsas", "Chalco",...: 1 1 1 1 1 1 1 1 1 1 ...
## $ Taxon         : Factor w/ 7 levels "Zea diploperennis",...: 1 1 1 1 1 1 1 1 1 1 ...
## $ Locality      : Factor w/ 272 levels "1_5_km_S_El_Limón",...: 207 207 207 207 207 207 207 207 207 207 ...
## $ Municipality  : Factor w/ 129 levels "Agua_Blanca",...: 36 36 36 36 36 36 36 36 36 36 ...
## $ State         : Factor w/ 19 levels "Chihuahua","Chinandega",...: 16 16 16 16 16 16 16 16 16 16 ...
## $ Country       : Factor w/ 3 levels "Guatemala","México",...: 2 2 2 2 2 2 2 2 2 2 ...
## $ Altitude      : int 1393 1393 1393 1393 1393 1393 1393 1393 1393 1393 ...
## $ Latitude      : Factor w/ 274 levels "12.89","12.89583333",...: 266 266 266 266 266 266 266 266 266 266 ...
## $ Longitude     : Factor w/ 275 levels "-100.0061111",...: 170 170 170 170 170 170 170 170 170 170 ...
## $ Sampling_date : int 2010 2010 2010 2010 2010 2010 2010 2010 2010 2010 ...
## $ Sample_name   : Factor w/ 3604 levels "AMEC_289_1","AMEC_289_10",...: 3323 3324 3325 3322 3326 3327 ...
```

summary(Data)

```
## DNASample_code      Library_plate      POB_CODE      POB_NUMBER
## 57_13 : 2 P_Teo2_Ex16_lib_8118: 93 CHPU : 124 Min. : 1.00
## 1_11 : 1 P_Teo2_Ex11_lib_8007: 92 BGUA : 122 1st Qu.:16.00
## 1_12 : 1 P_Teo3_21_lib_8116 : 92 BZAC : 122 Median :35.00
## 1_13 : 1 P_Teo_07_b : 91 BVPU : 117 Mean :34.07
## 1_14 : 1 P_Teo_08_b : 91 AMEC : 115 3rd Qu.:50.00
## 1_15 : 1 P_Teo_10_b : 91 BTEJ : 105 Max. :74.00
## (Other):3597 (Other) :3054 (Other):2899
## Accession Race Taxon
## JLHNM-661 : 30 : 386 Zea diploperennis : 136
## JSG-JMHC-626: 30 Balsas :1793 Zea luxurians : 111
## RMM-VHRO-241: 29 Chalco : 722 Zea mays ssp. huehuetenangensis: 38
## CIM27480 : 28 Durango : 87 Zea mays ssp. mexicana :1425
## JSG-JMHC-632: 28 Mesa Central: 563 Zea mays ssp. parviglumis :1793
## JSG-LCL-565 : 28 Nobogame : 53 Zea nicaraguensis : 20
## (Other) :3431 Zea perennis : 81
## Locality Municipality
## San_Nicolás_Buenos_Aires : 30 Teloloapan : 123
## Zacatlancillo_K80_Carr_51_cerro_El_Chivo: 30 Villa_Purificación: 117
## Arroyo_Tambor : 29 Tejupilco : 96
## El_Tepopote_Huista_La_Cofradía : 29 Guachinango : 95
## Calabacillas_Potrero_Michoacanes_Tuitán : 28 Huajicori : 91
## El_Estanco : 28 Tzitzio : 89
## (Other) :3430 (Other) :2993
## State Country Altitude Latitude
## Michoacán:1067 Guatemala: 120 Min. : 9 19.63527778: 40
## México : 809 México :3464 1st Qu.:1000 18.41666667: 30
## Jalisco : 516 Nicaragua: 20 Median :1437 19.17138889: 30
## Guerrero : 458 Mean :1518 19.75861111: 29
## Puebla : 153 3rd Qu.:1951 16.32388889: 28
## Nayarit : 106 Max. :2770 19.2175 : 28
## (Other) : 495 (Other) :3419
## Longitude Sampling_date Sample_name
## -97.55722222: 30 Min. :1968 AMEC_289_1 : 1
## -99.9675 : 30 1st Qu.:2005 AMEC_289_10: 1
## -104.85 : 29 Median :2007 AMEC_289_11: 1
## -101.3172222: 28 Mean :2006 AMEC_289_12: 1
## -101.9 : 28 3rd Qu.:2007 AMEC_289_13: 1
## -103.5797222: 28 Max. :2013 AMEC_289_14: 1
## (Other) :3431 NA's :13 (Other) :3598
```

colnames(Data)

```
## [1] "DNASample_code" "Library_plate" "POB_CODE" "POB_NUMBER"
## [5] "Accession" "Race" "Taxon" "Locality"
## [9] "Municipality" "State" "Country" "Altitude"
## [13] "Latitude" "Longitude" "Sampling_date" "Sample_name"
```

Preguntas básicas

¿Cuántas poblaciones hay y cuántos individuos por población?

Versión **corregida**, agrupando por Accession (unidad real de población del paper):

```
ind_por_poblacion <- Data %>% count(Accession, sort = TRUE)
ind_por_poblacion
```

```
##           Accession  n
## 1           JLHNM-661 30
## 2           JSG-JMHC-626 30
## 3           RMM-VHRO-241 29
## 4           CIM27480 28
## 5           JSG-JMHC-632 28
## 6           JSG-LCL-565 28
## 7           JSG-LCL-694 28
## 8           JSG-RMM-LCL-483 28
## 9           JSG-SRV-EAM-708 28
## 10          JLVTKV-717 27
## 11          JSG-LCL-JRP-702 27
## 12 JSG-RMM-LCL-487-2005 27
## 13          JSG-426-2004 25
## 14          JSG-LCL-684 25
## 15          JSG-SRV-606 25
## 16          JLNCM-657 23
## 17          RMM-FJSM-234 22
## 18          FAC-P-87 19
## 19          JSG-LCL-674 19
## 20          CIM27225 15
## 21          CIM27226 15
## 22          CIM27228 15
## 23          CIM27236 15
## 24          CIM27239 15
## 25          CIM27476 15
## 26          CMC-2 15
## 27          JACV-T-040 15
## 28          JACV-T-041 15
## 29          JACV-T-071 15
## 30          JLHNM-663 15
## 31          JLHNM-664 15
## 32          JLHNM-669 15
## 33          JLNCM-649 15
## 34 JSG Y RMM-439-2004 15
## 35 JSG Y SHP-464 15
## 36          JSG-431 15
## 37          JSG-JMHC-611 15
## 38          JSG-JMHC-612 15
## 39          JSG-JMHC-622 15
## 40          JSG-JMHC-628 15
## 41          JSG-JMHC-633 15
## 42          JSG-JMHC-636 15
## 43          JSG-JMHC-637 15
```

## 44	JSG-JMHC-638	15
## 45	JSG-JRP-ERG-542	15
## 46	JSG-LCL-564	15
## 47	JSG-LCL-566	15
## 48	JSG-LCL-689	15
## 49	JSG-LCL-JRP-700	15
## 50	JSG-RMM-LCL-473	15
## 51	JSG-RMM-LCL-477	15
## 52	JSG-RMM-LCL-486	15
## 53	JSG-RMM-LCL-514-2005	15
## 54	JSG-RMM-LCL-522-2005	15
## 55	JSG-RMM-LCL-524-2005	15
## 56	JSG-RMM-LCL-531	15
## 57	JSG-RMM-LCL-534-2005	15
## 58	JSG-RMM-LCL-537	15
## 59	JSG-SRV-604	15
## 60	JSG-SRV-EAM-705	15
## 61	JSG-SRV-EAM-709	15
## 62	JSG-SRV-EAM-710	15
## 63	RMM-11	15
## 64	RMM-FJSM-230	15
## 65	WTS-G6	15
## 66	CIM11362	14
## 67	CIM11365	14
## 68	CIM27215	14
## 69	CIM27224	14
## 70	CIM27227	14
## 71	CIM27234	14
## 72	CIM27235	14
## 73	CIM27242	14
## 74	CIM27475	14
## 75	CIM9479	14
## 76	CMC-1	14
## 77	JACV-T-010	14
## 78	JACV-T-039	14
## 79	JACV-T-046	14
## 80	JACV-T-057	14
## 81	JACV-T-062	14
## 82	JACV-T-063	14
## 83	JACV-T-068	14
## 84	JLHNM-660	14
## 85	JLHNM-662	14
## 86	JLHNM-666	14
## 87	JLNCM-647	14
## 88	JLNCM-651	14
## 89	JLVTKV-718	14
## 90	JLVTKV-721	14
## 91	JSG Y RMM-429	14
## 92	JSG Y RMM-438-2004	14
## 93	JSG Y RMM-449-2004	14
## 94	JSG Y RMM-454	14
## 95	JSG Y RMM-461-2005	14
## 96	JSG-467	14
## 97	JSG-JMHC-610	14

## 98	JSG-JMHC-615	14
## 99	JSG-JMHC-617	14
## 100	JSG-JMHC-621	14
## 101	JSG-JMHC-623	14
## 102	JSG-JMHC-629	14
## 103	JSG-JMHC-634	14
## 104	JSG-LCL-672	14
## 105	JSG-LCL-676	14
## 106	JSG-LCL-679	14
## 107	JSG-LCL-683	14
## 108	JSG-LCL-704	14
## 109	JSG-LCL-JGRF-586	14
## 110	JSG-LCL-JGRF-587	14
## 111	JSG-LCL-JRP-701	14
## 112	JSG-RMM-558	14
## 113	JSG-RMM-LCL-479	14
## 114	JSG-RMM-LCL-498-2005	14
## 115	JSG-RMM-LCL-523-2005	14
## 116	JSG-RMM-LCL-533-2005	14
## 117	JSG-RMM-LCL-536	14
## 118	JSG-RMM-LCL-551	14
## 119	JSG-RMM-LCL-552	14
## 120	LSC-TS-001	14
## 121	LSC-TS-003	14
## 122	RMM-FJSM-201	14
## 123	RMM-FJSM-204	14
## 124	RMM-FJSM-232	14
## 125	RMM-FJSM-VHRO-225	14
## 126	WTS-G5	14
## 127	WTS-H3	14
## 128	CIM27218	13
## 129	CIM27471	13
## 130	CIM27487	13
## 131	JACV-T-011	13
## 132	JACV-T-016	13
## 133	JACV-T-017	13
## 134	JACV-T-029	13
## 135	JACV-T-054	13
## 136	JACV-T-067	13
## 137	JACV-T-069a	13
## 138	JACV-T-070	13
## 139	JLHNM-668	13
## 140	JLNCM-642	13
## 141	JLNCM-646	13
## 142	JLVTKV-722	13
## 143	JSG Y RMM-440-2004	13
## 144	JSG Y RMM-446-2004	13
## 145	JSG Y RMM-448-2004	13
## 146	JSG-724	13
## 147	JSG-JMHC-616	13
## 148	JSG-JMHC-627	13
## 149	JSG-LCL-671	13
## 150	JSG-LCL-673	13
## 151	JSG-LCL-JGRF-590	13

152 JSG-LCL-JRP-MMR-712 13
 ## 153 JSG-RMM-LCL-497-2005 13
 ## 154 JSG-RMM-LCL-502-2005 13
 ## 155 JSG-RMM-LCL-520-2005 13
 ## 156 JSG-RMM-LCL-584 13
 ## 157 JSG-SRV-607 13
 ## 158 RMM-222 13
 ## 159 RMM-FJSM-206 13
 ## 160 RMM-FJSM-212 13
 ## 161 RMM-FJSM-231 13
 ## 162 WTS-G1 13
 ## 163 WTS-G2 13
 ## 164 CIM27243 12
 ## 165 CIM27543 12
 ## 166 JACV-T-001 12
 ## 167 JACV-T-003 12
 ## 168 JACV-T-045 12
 ## 169 JACV-T-050 12
 ## 170 JLNCM-643 12
 ## 171 JLNCM-645 12
 ## 172 JLNCM-653 12
 ## 173 JLVTKV-720 12
 ## 174 JSG Y LOS-40 12
 ## 175 JSG Y RMM-459 12
 ## 176 JSG-JMHC-630 12
 ## 177 JSG-JMHC-635 12
 ## 178 JSG-LCL-678 12
 ## 179 JSG-LCL-695 12
 ## 180 JSG-RMM-LCL-519-2005 12
 ## 181 JSG-RMM-LCL-548 12
 ## 182 RMM-14 12
 ## 183 RMM-219 12
 ## 184 RMM-FJSM-VHRO-224 12
 ## 185 RMM-FJSM-VHRO-226 12
 ## 186 RMM-VHRO-213 12
 ## 187 CIM27221 11
 ## 188 JACV-T-005 11
 ## 189 JACV-T-009 11
 ## 190 JACV-T-014 11
 ## 191 JACV-T-044 11
 ## 192 JACV-T-053 11
 ## 193 JACV-T-082 11
 ## 194 JLVTKV-719 11
 ## 195 JSG Y RMM-444-2004 11
 ## 196 JSG Y RMM-445 11
 ## 197 JSG Y RMM-450-2004 11
 ## 198 JSG Y RMM-463-2005 11
 ## 199 JSG-JMHC-609 11
 ## 200 JSG-JMHC-614 11
 ## 201 JSG-JMHC-624 11
 ## 202 JSG-JMHC-639 11
 ## 203 JSG-LCL-559 11
 ## 204 JSG-LCL-677 11
 ## 205 JSG-LCL-682 11

##	206	JSG-RMM-557	11
##	207	JSG-RMM-LCL-474	11
##	208	JSG-RMM-LCL-510-2005	11
##	209	JSG-RMM-LCL-516-2005	11
##	210	JSG-RMM-LCL-535-2005	11
##	211	RMM-VHRO-238	11
##	212	WTS-G3	11
##	213	CIM27216	10
##	214	CIM27229	10
##	215	CIM27233	10
##	216	CIM27473	10
##	217	CIM27520	10
##	218	CIM27521	10
##	219	CIM9478	10
##	220	JACV-T-024	10
##	221	JACV-T-035	10
##	222	JACV-T-037	10
##	223	JACV-T-048	10
##	224	JACV-T-065	10
##	225	JACV-T-073	10
##	226	JSG-593	10
##	227	JSG-JRP-ERG-544	10
##	228	JSG-LCL-680	10
##	229	RMM-FJSM-VHRO-223	10
##	230	WTS-H1	10
##	231	CIM10003	9
##	232	CIM27466	9
##	233	CIM27479	9
##	234	CMC-3	9
##	235	JACV-T-018	9
##	236	JACV-T-049	9
##	237	JACV-T-081	9
##	238	JLNCM-650	9
##	239	JLNCM-652	9
##	240	JSG Y RMM-447-2005	9
##	241	JSG Y RMM-455-2005	9
##	242	JSG Y RMM-462	9
##	243	JSG-JMHC-631	9
##	244	JSG-JMHC-640	9
##	245	JSG-LCL-670	9
##	246	JSG-LCL-681	9
##	247	JSG-LCL-686	9
##	248	CIM27237	8
##	249	JACV-T-022	8
##	250	JACV-T-059	8
##	251	JACV-T-074	8
##	252	JACV-T-078	8
##	253	JLNCM-654	8
##	254	JLNCM-655	8
##	255	JSG Y LOS-68	8
##	256	JSG-465-2004	8
##	257	JSG-JMHC-608	8
##	258	JSG-RMM-LCL-578	8
##	259	JSG-RMM-LCL-582	8

```
## 260          CIM11083  7
## 261          CIM27469  7
## 262          JLNCM-658  7
## 263   JSG Y RMM-443-2004  7
## 264   JSG Y RMM-456-2005  7
## 265          JSG-LCL-675  6
## 266 JSG-RMM-LCL-493-2005  6
## 267          WTS-G4  6
## 268          CIM27463  5
## 269          JACV-T-072  5
## 270          JSG Y LOS-75  5
## 271 JSG-RMM-LCL-517-2005  5
## 272          JSG-RMM-LCL-580  5
## 273          RMM-VHRO-237  5
## 274          CIM27464  3
## 275          JSG-RMM-LCL-475  3
## 276   JSG Y RMM-460-2005  2
```

```
nrow(ind_por_poblacion)  # 276, como reporta el paper
```

```
## [1] 276
```

Para contexto, así se ve si (incorrectamente, como en el análisis original) agrupamos por POB_CODE: solo 74 grupos, cada uno mezclando varias poblaciones reales.

```
ind_por_pobcode <- sort(table(Data$POB_CODE), decreasing = TRUE)
ind_por_pobcode
```

```
##
## CHPU BGUA BZAC BVPU AMEC BTEJ CHAP CHAL BEJU ZDNA BTZI CHUR BTAR TOLU BPCH BHUE
## 124 122 122 117 115 105 100 97 94 91 89 82 79 78 76 74
## CHTX MCUI BNOC BMAN BIXC BCOL BMAZ BOTZ NOBO MORO BTAC YURI INDA BCAR MZAM ZDJA
## 72 69 68 64 57 55 54 54 53 51 50 50 49 46 45 45
## DURA BJUA BOAX NDUR ZLJA ZPMI BTAL ZPJA BTCT BTEL BTUZ HUEH BHUI BZUL CHDF TARI
## 44 43 43 43 42 41 40 40 39 39 39 38 37 37 37 34
## CHMI SJER ZLOX BAPX MPUR BOLI CHGO ZLAB PENJ MORE TLAX HUAN BVBR MVIJ NICA BTIQ
## 32 30 29 28 28 27 27 27 26 24 24 23 20 20 20 17
## MALI PONC BMOR BQUE MDOB SNRA ZLJU BSAU COJU BRED
## 15 15 14 14 14 14 13 12 5 3
```

```
length(ind_por_pobcode)  # 74 -- esto NO es el número de poblaciones del paper
```

```
## [1] 74
```

¿Cuántos SNPs polimórficos hay por población?

Unimos primero la metadata (ya corregida) con el archivo .fam de PLINK:

```
fam <- read.table(ruta_fam, header = FALSE, stringsAsFactors = FALSE)
colnames(fam) <- c("FID", "IID", "PID", "MID", "SEX", "PHENO")

meta_fam <- merge(fam, Data, by.x = "IID", by.y = "Sample_name", all.x = TRUE)
sum(!is.na(meta_fam$Accession))  # debería ser 3604
```

```
## [1] 3604
```

Contamos SNPs polimórficos, ahora agrupando por Accession en vez de POB_CODE:

```
snpgdsBED2GDS(bed.fn = ruta_bed, bim.fn = ruta_bim, fam.fn = ruta_fam,  
              out.gdsfn = "teosinte.gds")
```

```
## Start file conversion from PLINK BED to SNP GDS ...  
##   BED file: '/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/T3604_33929_all.bed'  
##   SNP-major mode (Sample X SNP), 29.2M  
##   FAM file: '/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/T3604_33929_all.fam'  
##   BIM file: '/home/sam/Documents/sur_ecoevo_lab/data/teosinte/archivos/T3604_33929_all.bim'  
## Tue Aug 18 16:46:04 2026      (store sample id, snp id, position, and chromosome)  
##   start writing: 3604 samples, 33929 SNPs ...  
## [.....] 0%, ETC: --- [=====]  
## Tue Aug 18 16:46:04 2026      Done.  
## Optimize the access efficiency ...  
## Clean up the fragments of GDS file:  
##   open the file 'teosinte.gds' (29.3M)  
##   # of fragments: 39  
##   save to 'teosinte.gds.tmp'  
##   rename 'teosinte.gds.tmp' (29.3M, reduced: 252B)  
##   # of fragments: 18
```

```
genofile <- snpgdsOpen("teosinte.gds")  
  
samp <- read.gdsn(index.gdsn(genofile, "sample.id"))  
poblacion <- meta_fam$Accession[match(samp, meta_fam$IID)]  
  
poblaciones <- sort(unique(poblacion[!is.na(poblacion)]))  
res <- data.frame(Accession = poblaciones, n_poly = NA, n_snps = NA, n_ind = NA)  
  
for (i in seq_along(poblaciones)) {  
  p <- poblaciones[i]  
  idx <- which(poblacion == p)  
  af <- snpgdsSNPRateFreq(genofile, sample.id = samp[idx])  
  res$n_poly[i] <- sum(af$MinorFreq > 0, na.rm = TRUE)  
  res$n_snps[i] <- length(af$MinorFreq)  
  res$n_ind[i] <- length(idx)  
}  
snpgdsClose(genofile)  
  
res[order(res$n_poly, decreasing = TRUE), ]
```

```
##           Accession n_poly n_snps n_ind  
## 86           JLHNM-661 32087 33929 30  
## 181          JSG-LCL-674 30467 33929 19  
## 229 JSG-RMM-LCL-534-2005 30106 33929 15  
## 88           JLHNM-663 30042 33929 15  
## 89           JLHNM-664 29911 33929 15  
## 105          JLNCM-657 29836 33929 23  
## 225 JSG-RMM-LCL-523-2005 29819 33929 14
```

## 29	CIM27475	29768	33929	14
## 183	JSG-LCL-676	29639	33929	14
## 71	JACV-T-062	29505	33929	14
## 217	JSG-RMM-LCL-502-2005	29385	33929	13
## 227	JSG-RMM-LCL-531	29358	33929	15
## 162	JSG-JMHC-632	29281	33929	28
## 63	JACV-T-046	29085	33929	14
## 18	CIM27236	29084	33929	15
## 85	JLHNM-660	29077	33929	14
## 87	JLHNM-662	29031	33929	14
## 239	JSG-RMM-LCL-584	28894	33929	13
## 232	JSG-RMM-LCL-537	28801	33929	15
## 228	JSG-RMM-LCL-533-2005	28798	33929	14
## 128	JSG Y RMM-454	28714	33929	14
## 20	CIM27239	28668	33929	15
## 226	JSG-RMM-LCL-524-2005	28631	33929	15
## 186	JSG-LCL-679	28613	33929	14
## 77	JACV-T-070	28555	33929	13
## 189	JSG-LCL-682	28384	33929	11
## 184	JSG-LCL-677	28379	33929	11
## 62	JACV-T-045	28328	33929	12
## 78	JACV-T-071	28262	33929	15
## 97	JLNCM-647	28191	33929	14
## 187	JSG-LCL-680	28141	33929	10
## 215	JSG-RMM-LCL-497-2005	28085	33929	13
## 185	JSG-LCL-678	28032	33929	12
## 22	CIM27243	28024	33929	12
## 191	JSG-LCL-684	27801	33929	25
## 179	JSG-LCL-672	27800	33929	14
## 47	JACV-T-010	27761	33929	14
## 175	JSG-LCL-565	27725	33929	28
## 96	JLNCM-646	27672	33929	13
## 30	CIM27476	27660	33929	15
## 190	JSG-LCL-683	27612	33929	14
## 35	CIM27521	27580	33929	10
## 66	JACV-T-050	27546	33929	12
## 224	JSG-RMM-LCL-522-2005	27480	33929	15
## 230	JSG-RMM-LCL-535-2005	27466	33929	11
## 150	JSG-JMHC-616	27375	33929	13
## 123	JSG Y RMM-446-2004	27184	33929	13
## 13	CIM27228	27161	33929	15
## 166	JSG-JMHC-636	27050	33929	15
## 202	JSG-LCL-JRP-702	27028	33929	27
## 200	JSG-LCL-JRP-700	26992	33929	15
## 133	JSG Y RMM-461-2005	26979	33929	14
## 220	JSG-RMM-LCL-516-2005	26968	33929	11
## 68	JACV-T-054	26918	33929	13
## 180	JSG-LCL-673	26819	33929	13
## 21	CIM27242	26816	33929	14
## 80	JACV-T-073	26718	33929	10
## 98	JLNCM-649	26713	33929	15
## 156	JSG-JMHC-626	26679	33929	30
## 126	JSG Y RMM-449-2004	26666	33929	14
## 188	JSG-LCL-681	26656	33929	9

## 9	CIM27224	26621	33929	14
## 100	JLNCM-651	26608	33929	14
## 16	CIM27234	26585	33929	14
## 167	JSG-JMHC-637	26552	33929	15
## 168	JSG-JMHC-638	26503	33929	15
## 11	CIM27226	26460	33929	15
## 219	JSG-RMM-LCL-514-2005	26455	33929	15
## 12	CIM27227	26426	33929	14
## 48	JACV-T-011	26423	33929	13
## 222	JSG-RMM-LCL-519-2005	26383	33929	12
## 163	JSG-JMHC-633	26358	33929	15
## 223	JSG-RMM-LCL-520-2005	26339	33929	13
## 44	JACV-T-003	26311	33929	12
## 92	JLHNM-669	26307	33929	15
## 137	JSG-426-2004	26220	33929	25
## 61	JACV-T-044	26210	33929	11
## 45	JACV-T-005	26190	33929	11
## 26	CIM27469	26189	33929	7
## 67	JACV-T-053	26140	33929	11
## 210	JSG-RMM-LCL-479	26105	33929	14
## 238	JSG-RMM-LCL-582	26099	33929	8
## 25	CIM27466	26073	33929	9
## 147	JSG-JMHC-612	26051	33929	15
## 10	CIM27225	26041	33929	15
## 136	JSG Y SHP-464	25841	33929	15
## 91	JLHNM-668	25749	33929	13
## 125	JSG Y RMM-448-2004	25692	33929	13
## 122	JSG Y RMM-445	25612	33929	11
## 65	JACV-T-049	25592	33929	9
## 70	JACV-T-059	25455	33929	8
## 99	JLNCM-650	25444	33929	9
## 113	JSG Y LOS-40	25439	33929	12
## 196	JSG-LCL-704	25420	33929	14
## 159	JSG-JMHC-629	25418	33929	14
## 248	LSC-TS-003	25409	33929	14
## 201	JSG-LCL-JRP-701	25396	33929	14
## 151	JSG-JMHC-617	25383	33929	14
## 31	CIM27479	25348	33929	9
## 17	CIM27235	25347	33929	14
## 146	JSG-JMHC-611	25333	33929	15
## 182	JSG-LCL-675	25307	33929	6
## 90	JLHNM-666	25284	33929	14
## 5	CIM27215	25213	33929	14
## 249	RMM-11	25169	33929	15
## 14	CIM27229	25168	33929	10
## 131	JSG Y RMM-459	25168	33929	12
## 153	JSG-JMHC-622	25138	33929	15
## 144	JSG-JMHC-609	25112	33929	11
## 218	JSG-RMM-LCL-510-2005	25082	33929	11
## 3	CIM11362	25066	33929	14
## 148	JSG-JMHC-614	25016	33929	11
## 104	JLNCM-655	24995	33929	8
## 95	JLNCM-645	24991	33929	12
## 174	JSG-LCL-564	24963	33929	15

## 145	JSG-JMHC-610	24922	33929	14
## 81	JACV-T-074	24917	33929	8
## 165	JSG-JMHC-635	24835	33929	12
## 94	JLNCM-643	24760	33929	12
## 157	JSG-JMHC-627	24738	33929	13
## 27	CIM27471	24659	33929	13
## 236	JSG-RMM-LCL-578	24652	33929	8
## 19	CIM27237	24645	33929	8
## 197	JSG-LCL-JGRF-586	24548	33929	14
## 231	JSG-RMM-LCL-536	24475	33929	14
## 149	JSG-JMHC-615	24465	33929	14
## 198	JSG-LCL-JGRF-587	24463	33929	14
## 247	LSC-TS-001	24434	33929	14
## 241	JSG-SRV-606	24323	33929	25
## 51	JACV-T-017	24314	33929	13
## 255	RMM-FJSM-206	24292	33929	13
## 8	CIM27221	24259	33929	11
## 119	JSG Y RMM-440-2004	24222	33929	13
## 124	JSG Y RMM-447-2005	24182	33929	9
## 69	JACV-T-057	24178	33929	14
## 164	JSG-JMHC-634	24144	33929	14
## 54	JACV-T-024	24135	33929	10
## 134	JSG Y RMM-462	24127	33929	9
## 7	CIM27218	24055	33929	13
## 127	JSG Y RMM-450-2004	24027	33929	11
## 216	JSG-RMM-LCL-498-2005	23972	33929	14
## 209	JSG-RMM-LCL-477	23962	33929	15
## 143	JSG-JMHC-608	23921	33929	8
## 72	JACV-T-063	23897	33929	14
## 6	CIM27216	23881	33929	10
## 106	JLNCM-658	23865	33929	7
## 117	JSG Y RMM-438-2004	23840	33929	14
## 205	JSG-RMM-558	23836	33929	14
## 49	JACV-T-014	23789	33929	11
## 121	JSG Y RMM-444-2004	23785	33929	11
## 46	JACV-T-009	23758	33929	11
## 55	JACV-T-029	23717	33929	13
## 43	JACV-T-001	23678	33929	12
## 82	JACV-T-078	23650	33929	8
## 58	JACV-T-039	23551	33929	14
## 237	JSG-RMM-LCL-580	23524	33929	5
## 172	JSG-JRP-ERG-544	23474	33929	10
## 214	JSG-RMM-LCL-493-2005	23403	33929	6
## 4	CIM11365	23299	33929	14
## 101	JLNCM-652	23272	33929	9
## 254	RMM-FJSM-204	23233	33929	14
## 135	JSG Y RMM-463-2005	23170	33929	11
## 259	RMM-FJSM-232	23156	33929	14
## 15	CIM27233	23130	33929	10
## 103	JLNCM-654	23110	33929	8
## 129	JSG Y RMM-455-2005	23038	33929	9
## 102	JLNCM-653	22916	33929	12
## 56	JACV-T-035	22894	33929	10
## 169	JSG-JMHC-639	22885	33929	11

## 213	JSG-RMM-LCL-487-2005	22880	33929	27
## 176	JSG-LCL-566	22866	33929	15
## 118	JSG Y RMM-439-2004	22846	33929	15
## 116	JSG Y RMM-429	22838	33929	14
## 154	JSG-JMHC-623	22641	33929	14
## 130	JSG Y RMM-456-2005	22640	33929	7
## 120	JSG Y RMM-443-2004	22634	33929	7
## 76	JACV-T-069a	22620	33929	13
## 50	JACV-T-016	22599	33929	13
## 178	JSG-LCL-671	22564	33929	13
## 170	JSG-JMHC-640	22503	33929	9
## 39	CMC-1	22434	33929	14
## 158	JSG-JMHC-628	22407	33929	15
## 206	JSG-RMM-LCL-473	22326	33929	15
## 252	RMM-222	22301	33929	13
## 245	JSG-SRV-EAM-709	22209	33929	15
## 193	JSG-LCL-689	22196	33929	15
## 57	JACV-T-037	22074	33929	10
## 246	JSG-SRV-EAM-710	21958	33929	15
## 199	JSG-LCL-JGRF-590	21920	33929	13
## 84	JACV-T-082	21879	33929	11
## 75	JACV-T-068	21823	33929	14
## 155	JSG-JMHC-624	21781	33929	11
## 152	JSG-JMHC-621	21586	33929	14
## 177	JSG-LCL-670	21558	33929	9
## 211	JSG-RMM-LCL-483	21531	33929	28
## 73	JACV-T-065	21426	33929	10
## 142	JSG-724	21329	33929	13
## 79	JACV-T-072	21261	33929	5
## 64	JACV-T-048	21194	33929	10
## 83	JACV-T-081	21190	33929	9
## 41	CMC-3	21168	33929	9
## 60	JACV-T-041	21158	33929	15
## 53	JACV-T-022	21041	33929	8
## 28	CIM27473	21028	33929	10
## 207	JSG-RMM-LCL-474	20844	33929	11
## 171	JSG-JRP-ERG-542	20809	33929	15
## 204	JSG-RMM-557	20776	33929	11
## 40	CMC-2	20572	33929	15
## 160	JSG-JMHC-630	20522	33929	12
## 74	JACV-T-067	20273	33929	13
## 23	CIM27463	20183	33929	5
## 256	RMM-FJSM-212	20144	33929	13
## 266	RMM-VHRO-237	20078	33929	5
## 258	RMM-FJSM-231	20038	33929	13
## 240	JSG-SRV-604	19872	33929	15
## 221	JSG-RMM-LCL-517-2005	19864	33929	5
## 36	CIM27543	19763	33929	12
## 140	JSG-467	19679	33929	14
## 52	JACV-T-018	19672	33929	9
## 260	RMM-FJSM-234	19645	33929	22
## 93	JLNCM-642	19585	33929	13
## 242	JSG-SRV-607	19574	33929	13
## 59	JACV-T-040	19561	33929	15

## 161	JSG-JMHC-631	19482	33929	9
## 139	JSG-465-2004	19447	33929	8
## 34	CIM27520	18645	33929	10
## 244	JSG-SRV-EAM-708	18460	33929	28
## 192	JSG-LCL-686	18329	33929	9
## 138	JSG-431	18015	33929	15
## 212	JSG-RMM-LCL-486	17824	33929	15
## 275	WTS-H1	17761	33929	10
## 173	JSG-LCL-559	17709	33929	11
## 268	RMM-VHRO-241	16492	33929	29
## 265	RMM-VHRO-213	16291	33929	12
## 257	RMM-FJSM-230	16141	33929	15
## 24	CIM27464	15714	33929	3
## 115	JSG Y LOS-75	15007	33929	5
## 253	RMM-FJSM-201	14588	33929	14
## 38	CIM9479	14138	33929	14
## 208	JSG-RMM-LCL-475	13286	33929	3
## 32	CIM27480	13276	33929	28
## 251	RMM-219	13159	33929	12
## 233	JSG-RMM-LCL-548	12989	33929	12
## 267	RMM-VHRO-238	12852	33929	11
## 132	JSG Y RMM-460-2005	12801	33929	2
## 194	JSG-LCL-694	12640	33929	28
## 261	RMM-FJSM-VHRO-223	12294	33929	10
## 264	RMM-FJSM-VHRO-226	12208	33929	12
## 262	RMM-FJSM-VHRO-224	12128	33929	12
## 250	RMM-14	12052	33929	12
## 263	RMM-FJSM-VHRO-225	11824	33929	14
## 243	JSG-SRV-EAM-705	11749	33929	15
## 203	JSG-LCL-JRP-MMR-712	11417	33929	13
## 234	JSG-RMM-LCL-551	8443	33929	14
## 235	JSG-RMM-LCL-552	8246	33929	14
## 276	WTS-H3	8061	33929	14
## 1	CIM10003	7429	33929	9
## 271	WTS-G3	6942	33929	11
## 269	WTS-G1	6613	33929	13
## 114	JSG Y LOS-68	6282	33929	8
## 195	JSG-LCL-695	6024	33929	12
## 273	WTS-G5	5961	33929	14
## 270	WTS-G2	4992	33929	13
## 274	WTS-G6	4894	33929	15
## 272	WTS-G4	4865	33929	6
## 37	CIM9478	4853	33929	10
## 107	JLVTKV-717	4657	33929	27
## 112	JLVTKV-722	4529	33929	13
## 108	JLVTKV-718	4327	33929	14
## 111	JLVTKV-721	4276	33929	14
## 109	JLVTKV-719	4236	33929	11
## 110	JLVTKV-720	4119	33929	12
## 33	CIM27487	3978	33929	13
## 2	CIM11083	3898	33929	7
## 42	FAC-P-87	2635	33929	19
## 141	JSG-593	2370	33929	10

Advertencia: al repartir los mismos 3604 individuos entre 276 poblaciones (en vez de 74), muchas poblaciones quedan con pocos individuos, y el estimado de polimorfismo se vuelve más ruidoso para esas. Vale la pena revisar la distribución de tamaños antes de interpretar la tabla de arriba:

```
table(cut(ind_por_poblacion$n, breaks = c(0, 2, 5, 10, 20, 50)))
```

```
##
##   (0,2]   (2,5]   (5,10] (10,20] (20,50]
##       1       8      55     195     17
```

¿Geolocalización de cada población?

```
Data$Latitude <- as.numeric(as.character(Data$Latitude))
Data$Longitude <- as.numeric(as.character(Data$Longitude))

geo_poblacion <- Data %>%
  group_by(Accession) %>%
  summarise(n_ind = n(), lat = unique(Latitude), lon = unique(Longitude),
            alt = unique(Altitude), POB_CODE = unique(POB_CODE), .groups = "drop")

geo_poblacion
```

```
## # A tibble: 276 x 6
##   Accession n_ind  lat    lon  alt POB_CODE
##   <fct>      <int> <dbl> <dbl> <int> <fct>
## 1 CIM10003      9  19.5 -104.  2250 ZDJA
## 2 CIM11083      7  12.9 -87.0    9 NICA
## 3 CIM11362     14  19.3 -99.1  2200 CHDF
## 4 CIM11365     14  20.7 -102.  1710 MDOB
## 5 CIM27215     14  19.5 -98.8  2280 CHTX
## 6 CIM27216     10  19.5 -98.8  2263 CHTX
## 7 CIM27218     13  19.5 -98.9  2381 CHTX
## 8 CIM27221     11  19.2 -98.8  2340 CHAL
## 9 CIM27224     14  19.2 -98.9  2267 CHAL
## 10 CIM27225     15  19.1 -98.8  2425 AMEC
## # i 266 more rows
```

```
nrow(geo_poblacion) # 276
```

```
## [1] 276
```

En el análisis original, agrupar por POB_CODE y calcular el rango de lat/lon dentro de cada grupo daba valores grandes en varios códigos, que se interpretaron como posibles “poblaciones inconsistentes” (mal etiquetadas, mezcladas, o con coordenadas erróneas). En realidad, ese rango se explica solo por cuántas Accession distintas mezcla cada POB_CODE — no es un problema de los datos:

```
geo_pob_code <- Data %>%
  group_by(POB_CODE) %>%
  summarise(n_accessions = n_distinct(Accession),
```

```

lat_range = max(Latitude) - min(Latitude),
lon_range = max(Longitude) - min(Longitude), .groups = "drop") %>%
arrange(desc(lat_range + lon_range))

head(geo_pob_code, 15)

```

```

## # A tibble: 15 x 4
##   POB_CODE n_accessions lat_range lon_range
##   <fct>      <int>      <dbl>      <dbl>
## 1 CHMI          3    0.259    0.315
## 2 BMAZ          6    0.198    0.322
## 3 MZAM          4    0.199    0.275
## 4 BTCT          2    0.191    0.257
## 5 BGUA          8    0.210    0.199
## 6 CHPU          8    0.178    0.220
## 7 BEJU          7    0.125    0.236
## 8 TOLU          6    0.118    0.240
## 9 BCOL          4    0.0875   0.260
## 10 BTZI         7    0.228    0.105
## 11 BNOC         6    0.136    0.195
## 12 CHTX         6    0.197    0.120
## 13 CHDF         3    0.127    0.182
## 14 INDA         4    0.176    0.132
## 15 BTUZ         4    0.208    0.0890

```

```
cor(geo_pob_code$n_accessions, geo_pob_code$lat_range + geo_pob_code$lon_range)
```

```
## [1] 0.5932608
```

Una correlación alta aquí confirma que el “rango” es aritmética de agrupación (varias poblaciones reales bajo un mismo código), no coordenadas mal capturadas.

¿Fecha específica de recolección o gradiente de varias décadas?

```
table(Data$Sampling_date) |> sort(decreasing = TRUE)
```

```

##
## 2007 2005 2004 2003 2008 2009 2010 2002 2012 1976 1968 1969 1984 1983 2006 1978
## 1979 351 309 262 209 119 117 104 29 24 14 14 13 12 10 9
## 2013 1991
## 9 7

```

```
range(Data$Sampling_date, na.rm = TRUE)
```


```
## [1] 1968 2013
```

```

hist(Data$Sampling_date, breaks = 20, col = "deepskyblue3", border = "white",
main = "Distribución de años de muestreo", xlab = "Año de muestreo",
ylab = "Número de individuos")

```

Distribución de años de muestreo



¿Posición genómica aproximada?

```
bim <- read.table(ruta_bim, header = FALSE, stringsAsFactors = FALSE)
colnames(bim) <- c("CHR", "SNP", "CM", "BP", "A1", "A2")

table(bim$CHR) # SNPs por cromosoma
```

```
##
##      1      2      3      4      5      6      7      8      9     10
## 5486 4151 3935 2997 4028 2722 3080 2896 2414 2220
```

```
summary(bim$BP)
```

```
##      Min.   1st Qu.   Median     Mean   3rd Qu.     Max.
##  10232   34595261 137391485 120528242 181126820 301168145
```

```
bim %>%
  group_by(CHR) %>%
  summarise(n_snps = n(), min_BP = min(BP), max_BP = max(BP), .groups = "drop")
```

```
## # A tibble: 10 x 4
##       CHR n_snps min_BP max_BP
```

##	<int>	<int>	<int>	<int>
## 1	1	5486	992727	301168145
## 2	2	4151	10232	236973204
## 3	3	3935	1261965	232044134
## 4	4	2997	30681	241030367
## 5	5	4028	536169	217608792
## 6	6	2722	272264	169083700
## 7	7	3080	32638	176550961
## 8	8	2896	96346	175698433
## 9	9	2414	318789	156422039
## 10	10	2220	629096	149597102

¿Quién es la referencia?

Draft ZeaGBSv2.7.

Notas finales

- Duda: ¿POB_CODE es el número de poblaciones?~~ Resuelto: no, son 74 sitios/regiones que agrupan las 276 poblaciones reales (**Accession**).
- Pendiente (sin resolver): ¿es suficiente el año de recolección para asumir el clima al momento de la colecta, dado que WorldClim son promedios climáticos históricos (~1970-2000) y no el clima del año específico de muestreo?
- Se utilizarán las variables bioclimáticas extraídas de WorldClim, recortadas geográficamente solo a Mesoamérica