

Predicción de diversidad nucleotídica en teocintle a partir de variables bioclimáticas mediante una red neuronal

Alumna: Samantha Melissa Pacheco Gómez

Profesor: Dr. Mario Alan Quiroz Juárez

1. Introducción

El teocintle comprende los parientes silvestres del maíz dentro del género *Zea* y representa un sistema importante para estudiar la relación entre diversidad genómica, ambiente y conservación. Estas plantas se distribuyen en paisajes ambientalmente heterogéneos de México y Centroamérica, desde zonas bajas hasta regiones de más de 2,000 m.s.n.m., y ocupan hábitats como campos de maíz, bosques templados o tropicales, laderas rocosas y zonas con disturbio antropogénico. Debido a que los teocintles conservan variación genética relevante para la evolución y el mejoramiento del maíz, entender cómo se distribuye su diversidad genómica es importante tanto para estudios evolutivos como para estrategias de conservación (Rivera-Rodríguez et al., 2023).

Este proyecto parte de los datos generados por Rivera-Rodríguez et al. (2023), quienes evaluaron la diversidad genómica y estructura poblacional de teocintle usando 3,604 individuos, 276 poblaciones y 33,929 SNPs. Su estudio mostró que la diversidad genética del género *Zea* está fuertemente estructurada por taxonomía y geografía, y que *Zea mays* ssp. *parviglumis* y *Zea mays* ssp. *mexicana* presentan algunos de los valores más altos de diversidad genómica dentro del conjunto original.

A partir de esa base, este trabajo reformula el problema desde una perspectiva predictiva: evaluar si variables bioclimáticas resumidas mediante análisis de componentes principales pueden predecir la diversidad nucleotídica por píxel en *Zea mays* ssp. *parviglumis* y *Zea mays* ssp. *mexicana*. La diversidad nucleotídica, representada como π , mide el número promedio de diferencias de nucleótidos por sitio entre dos secuencias de ADN elegidas al azar dentro de una población o muestra (Nei & Li, 1979). En este proyecto, π se calculó para los individuos agrupados dentro de cada píxel geográfico, por lo que se utilizó como una estimación local de diversidad genómica y como variable respuesta del modelo.

2. Planteamiento del problema

El objetivo de esta sección fue plantear si las diferencias ambientales entre píxeles pueden predecir diferencias en la diversidad nucleotídica local del teocintle. Para ello, π por píxel se utilizó como variable respuesta, mientras que los componentes principales de las variables bioclimáticas de WorldClim y la identidad taxonómica se usaron como variables predictoras.

Debido a que π es una variable continua, el análisis se formuló como un problema de regresión supervisada. Por lo tanto, el desempeño del modelo se evaluó con RMSE, MAE y R^2 , en lugar de accuracy clásica. También se calculó un desempeño porcentual aproximado, derivado del RMSE relativo al rango observado de π , únicamente como una forma más intuitiva de interpretar el error del modelo.

3. Datos y procesamiento

Los datos genómicos utilizados provienen del estudio de Rivera-Rodríguez et al. (2023), basado en genotipificación por secuenciación. El conjunto original incluye una matriz final de 33,929 SNPs para 3,604 individuos de teocintle. En este proyecto no se trabajó con todos los taxa disponibles, sino únicamente con *Zea mays* ssp. *parviglumis* y *Zea mays* ssp. *mexicana*, decisión tomada a partir de que son los taxa con mayor cobertura geográfica y número de poblaciones dentro del conjunto original, además de presentar valores altos de diversidad genómica. Asimismo, permitió evitar que el modelo aprendiera principalmente diferencias entre especies muy divergentes, concentrando el análisis en dos subespecies comparables, ampliamente distribuidas y biológicamente relevantes.

El procesamiento inició con una tabla de metadatos que contenía coordenadas geográficas, identificadores de muestra y taxón. Primero se eliminaron individuos sin coordenadas válidas y después se conservaron únicamente las muestras de *parviglumis* y *mexicana*. Posteriormente, cada individuo fue asignado a un píxel geográfico a partir de sus coordenadas y de la cuadrícula del raster de WorldClim para Mesoamérica, un subconjunto de la resolución de 30 segundos que yo misma corté previamente. Para cada píxel con al menos 10 individuos, se calculó la diversidad nucleotídica promedio.

Finalmente, se extrajeron las 19 variables bioclimáticas de WorldClim correspondientes al centroide de cada píxel. La matriz final incluyó 204 píxeles: 93 correspondientes a *Zea mays ssp. mexicana* y 111 a *Zea mays ssp. parviglumis*, ninguno tuvo una pertenencia mixta. El rango observado de π fue de 0.1115 a 0.2879, con una amplitud total de 0.1764.

4. Exploración de datos

Antes de entrenar el modelo, se realizaron visualizaciones exploratorias para revisar la calidad y estructura de los datos. El mapa de π (**fig. 1**) permitió observar la distribución espacial de los píxeles analizados en Mesoamérica. La distribución de individuos por píxel (**fig. 2, a**), permitió justificar el filtro mínimo de 10 individuos, evitando estimaciones de π demasiado inestables. La distribución de π (**fig. 2, b**), mostró el rango y la forma de la variable respuesta, lo cual es importante para interpretar posteriormente el RMSE. También se evaluó la correlación entre las variables bioclimáticas y se aplicó un análisis de componentes principales debido a su alta correlación, decidiendo reducir la

dimensionalidad ambiental y evitar introducir variables redundantes directamente en la red neuronal.




Figura 1. Distribución espacial de la diversidad nucleotídica (π) por píxel en Mesoamérica. Cada punto representa un píxel con al menos 10 individuos de teocintle. El color indica el valor de π calculado para ese píxel, con tonos claros para menor diversidad y tonos rojos oscuros para mayor diversidad. La figura muestra que la diversidad nucleotídica presenta variación espacial, con valores principalmente intermedios a altos concentrados en el occidente y centro de México.




Figura 2. Distribución de individuos y diversidad nucleotídica por píxel. a) Distribución del número de individuos asignados a cada píxel geográfico antes del filtrado. b) Distribución de la diversidad nucleotídica (π) calculada por píxel. La mayoría de los valores se concentra entre aproximadamente 0.21 y 0.28, aunque se observan algunos píxeles con menor diversidad, los cuales se redujeron después del filtrado por píxel con $n \geq 10$.

5. Análisis de componentes principales

El PCA (**fig. 3**), se utilizó para transformar las 19 variables bioclimáticas y después reducir los ejes ambientales. Los primeros componentes principales capturaron la mayor parte de la varianza ambiental y fueron interpretados como gradientes de temperatura, estacionalidad, precipitación y rango diurno, por las variables que aportaban a cada componente.

A partir del scree plot se definieron tres configuraciones de entrada para la red neuronal:

- Configuración A: PC1, PC2, PC3 y la variable binaria de subespecie.
- Configuración B: PC1, PC2, PC3, PC4 y la variable binaria de subespecie.
- Configuración C: PC1, PC2, PC3, PC4, PC5 y la variable binaria de subespecie.

La comparación entre estas configuraciones permitió evaluar si incluir componentes ambientales adicionales mejoraba la capacidad predictiva del modelo o si solo agregaba más variables sin reducir el error de validación. Esta comparación no mide causalidad biológica, sino desempeño predictivo.




Figura 3. Varianza explicada por componente principal y varianza acumulada del PCA bioclimático. Las barras muestran el porcentaje de varianza explicada por cada componente principal, mientras que la línea indica la varianza acumulada. Los primeros cinco componentes resumen más del 95% de la variación ambiental, por lo que fueron considerados como predictores en la configuración final del modelo.

6. Modelo de red neuronal

Se implementó una red neuronal artificial para regresión usando keras3 en R, siguiendo una red feed-forward con capas densas. La arquitectura final incluyó dos capas ocultas con activación ReLU y una capa de salida lineal para predecir un valor continuo como π .

Los hiperparámetros principales fueron:

- Primera capa oculta: 24 neuronas.
- Segunda capa oculta: 12 neuronas.
- Activación en capas ocultas: ReLU.
- Activación de salida: lineal.
- Regularización L2: 0.005.
- Dropout: 0.25.
- Optimizador: Adam.
- Learning rate: 0.0005.
- Función de pérdida: MSE.
- Métrica interna: MAE.
- Batch size: 32.
- Early stopping para detener el entrenamiento cuando la validación deja de mejorar.

Se usó regularización L2 para penalizar pesos excesivamente grandes y reducir el riesgo de sobreajuste. También se aplicó dropout de 0.25, obligando al modelo a no depender demasiado de combinaciones específicas de neuronas y favoreciendo la generalización.

El learning rate de 0.0005 permite actualizaciones más graduales de los pesos, lo cual puede ser útil en conjuntos de datos pequeños y con riesgo de sobreajuste.

7. Validación cruzada

Para evaluar el desempeño del modelo, se utilizó validación cruzada de 10 folds. Los 204 píxeles fueron divididos aleatoriamente en 10 subconjuntos de tamaño similar, cuatro folds con 21 píxeles y seis folds con 20 píxeles.

En cada fold, la estandarización de las variables predictoras y de la variable respuesta se calculó usando únicamente el conjunto de entrenamiento. Los parámetros obtenidos en entrenamiento se aplicaron después al conjunto de validación, evitando fuga de información entre entrenamiento y validación.

8. Resultados de validación cruzada

La configuración C obtuvo el mejor desempeño en validación cruzada. Esta configuración incluyó PC1, PC2, PC3, PC4, PC5 y la variable binaria de subespecie. Su RMSE promedio de validación fue 0.0240, menor que el de la configuración A (0.0267) y B (0.0276). También presentó el mayor R^2 de validación, con un valor promedio de 0.533, en comparación con 0.419 para A y 0.370 para B.

Configuración	RMSE medio	train	RMSE medio	val	MAE medio	val	R^2 medio	train	R^2 medio	val	Desempeño medio	val
C	0.0237		0.0240		0.0188		0.609		0.533		86.4	
A	0.0266		0.0267		0.0206		0.508		0.419		84.8	
B	0.0287		0.0276		0.0214		0.401		0.370		84.4	

La diferencia entre el RMSE de entrenamiento y validación para la configuración C fue mínima. Esto sugiere que el modelo no presentó sobreajuste marcado durante la validación cruzada. Además, el RMSE de validación de 0.0240 equivale aproximadamente al 13.6% del rango observado de π , por lo que el desempeño porcentual aproximado fue de 86.4%.

Estos resultados indican que incluir hasta PC5 aportó información predictiva adicional para explicar la variación espacial en π . Sin embargo, esta interpretación debe entenderse como predictiva y no causal: los componentes principales resumen gradientes ambientales correlacionados, por lo que no se puede afirmar que un componente específico cause cambios en diversidad nucleotídica sin análisis adicionales.

9. Modelo final entrenado con todos los datos

Después de seleccionar la configuración C, se entrenó un modelo final usando todos los datos disponibles. Este modelo se utilizó para generar predicciones finales, residuos y análisis de interpretación, pero no como estimación principal de generalización.

El modelo final obtuvo:

- RMSE de entrenamiento completo: 0.02309.
- MAE de entrenamiento completo: 0.01806.
- R^2 de entrenamiento completo: 0.6302.

El R^2 de 0.6302 indica que el modelo final explicó aproximadamente 63% de la variación observada en π dentro del conjunto completo. Este valor sugiere una capacidad predictiva moderada. Sin

embargo, debido a que el modelo fue entrenado con todos los datos, la evaluación principal de generalización debe basarse en las métricas del 10-fold CV.

10. Diagnóstico de predicciones y residuos

El gráfico de π observado contra π predicho (**fig. 4, a**), mostró una tendencia positiva, indicando que el modelo captura parte de la variación general en diversidad nucleotídica. Sin embargo, también se observó que las predicciones tienden a comprimirse hacia valores intermedios. Esto significa que el modelo predice mejor valores comunes de π que valores extremos.

El análisis de residuos (**fig. 4, b**), mostró una diferencia clara entre píxeles con π bajo y píxeles con valores típicos de π . Para píxeles con π bajo (<0.19), el RMSE fue 0.0409 y el sesgo medio fue -0.0359. Como el residuo se definió como observado menos predicho, este sesgo negativo indica que el modelo sobreestima sistemáticamente los valores bajos de π . En cambio, para píxeles con π típico (≥ 0.19), el RMSE fue menor, 0.0194, y el sesgo medio fue cercano a cero, 0.00471.

Esto sugiere que el modelo generaliza mejor para valores comunes de diversidad, pero tiene dificultades para capturar píxeles con diversidad nucleotídica particularmente baja. Una posible explicación es que los valores bajos de π son menos frecuentes en el conjunto de datos y pueden estar asociados a procesos no incluidos explícitamente en el modelo, como historia demográfica local, aislamiento, deriva genética, tamaño efectivo poblacional o estructura espacial fina.




Figura 4. Diagnóstico de predicción del modelo final. a) Relación entre la diversidad nucleotídica observada (π observado) y la diversidad nucleotídica predicha por el modelo. La línea punteada representa la correspondencia esperada entre valores observados y predichos. b) Distribución de residuos en función de π predicho, donde el residuo se calculó como observado menos predicho. La línea horizontal indica residuo igual a cero; valores por debajo de la línea representan sobreestimación del modelo y valores por encima representan subestimación.

11. Interpretación del modelo con SHAP

Para interpretar el modelo final se calcularon valores SHAP, que estiman cuánto contribuye cada variable a las predicciones de π . La importancia global se calculó como el promedio del valor absoluto de SHAP por variable; por ello, las variables con valores más altos fueron las que más modificaron las predicciones del modelo.

El análisis (**fig. 5**), mostró que PC5 fue la variable con mayor importancia global, seguida por PC3_precipitacion y la variable taxonómica *es_parviglumis*. Este resultado es consistente con la validación cruzada, ya que la configuración C fue la única que incluyó PC5 y también fue la que obtuvo el menor error de validación. La importancia de la variable taxonómica indica que la identidad taxonómica también aportó información, pero no fue el único factor relevante.

En conjunto, SHAP sugiere que el modelo combinó información ambiental y taxonómica para predecir π . Sin embargo, como las variables ambientales fueron resumidas mediante PCA, estos resultados deben interpretarse como contribuciones de gradientes ambientales compuestos y no como efectos causales de variables bioclimáticas aisladas.




Figura 5. Importancia global de variables según valores SHAP. La gráfica muestra la importancia media absoluta de cada variable en las predicciones del modelo final. PC5 fue la variable con mayor contribución global, seguida por PC3_precipitacion y la variable taxonómica. Esto sugiere que el modelo utilizó tanto información ambiental resumida por PCA como identidad taxonómica para predecir la diversidad nucleotídica (π).

12. Limitaciones

Una limitación importante es el tamaño del conjunto de datos. Aunque el dataset original incluye miles de individuos, la unidad de análisis de este proyecto fue el píxel, por lo que el modelo final trabajó con 204 observaciones. Esto limita la complejidad del modelo que puede entrenarse de forma confiable.

Otra limitación es la estructura espacial. Los folds fueron asignados aleatoriamente, por lo que píxeles cercanos pueden quedar divididos entre entrenamiento y validación. Si existe autocorrelación espacial, la validación aleatoria puede producir una estimación optimista del desempeño.

También debe considerarse que π es una medida resumen de diversidad genética. Aunque es útil para comparar diversidad entre píxeles, no distingue por sí sola entre procesos evolutivos como selección, deriva, flujo génico, aislamiento o historia demográfica. Por lo tanto, las relaciones aprendidas por la red neuronal deben interpretarse como asociaciones predictivas, no como evidencia causal directa.

Finalmente, los componentes principales resumen combinaciones de variables bioclimáticas, reduciendo la redundancia entre predictores, pero también dificulta la interpretación biológica directa de cada componente.

13. Conclusiones

Este trabajo implementó un pipeline que integra datos genómicos, variables bioclimáticas y una red neuronal para predecir diversidad nucleotídica en teocintle. La configuración C, que incluyó los primeros cinco componentes principales de las variables bioclimáticas y la identidad taxonómica, obtuvo el mejor desempeño en validación cruzada, con un RMSE promedio de validación de 0.0240 y un R^2 promedio de validación de 0.533.

La similitud entre las métricas de entrenamiento y validación indica que el modelo no presentó sobreajuste marcado durante el CV. Sin embargo, el análisis de residuos mostró que el modelo sobreestima los píxeles con baja diversidad nucleotídica, lo que indica que no todos los rangos de π son predichos con la misma precisión.

El análisis SHAP permitió interpretar el modelo final y mostró que PC5, PC3_precipitacion y la identidad taxonómica fueron las variables más influyentes en las predicciones. Esto sugiere que la diversidad nucleotídica por píxel no fue predicha únicamente por la subespecie, sino también por gradientes ambientales resumidos mediante PCA.

En conjunto, los resultados sugieren que las variables ambientales contienen señal predictiva sobre la variación espacial de π en *Zea mays* ssp. *parviglumis* y *Zea mays* ssp. *mexicana*. No obstante, el modelo debe interpretarse como una aproximación predictiva inicial, y no como una prueba causal de los efectos ambientales sobre la diversidad genética.

14. Referencias

- Rivera-Rodríguez DM, Mastretta-Yanes A, Wegier A, De la Cruz Larios L, Santacruz-Ruvalcaba F, Ruiz Corral JA, et al. (2023) Genomic diversity and population structure of teosinte (*Zea* spp.) and its conservation implications. PLoS ONE 18(10): e0291944. <https://doi.org/10.1371/journal.pone.0291944>
- Equipo de Posit (2025). RStudio: Entorno de desarrollo integrado para R.
- Posit Software, PBC, Boston, MA. URL <http://www.posit.co/>.
- M. Nei, & W.H. Li, Mathematical model for studying genetic variation in terms of restriction endonucleases., Proc. Natl. Acad. Sci. U.S.A. 76 (10) 5269-5273, <https://doi.org/10.1073/pnas.76.10.5269> (1979).